

# 时间依赖的连续概念空间：基于时变高斯过程的语义流形建模

Aristotle

2026 年 9 月 16 日

## 摘要

本文提出一种基于时变高斯过程（Time-Varying Gaussian Process）的连续概念空间建模框架。与传统静态词嵌入不同，本框架将概念建模为高维语义流形上的随机过程，通过引入时间依赖的核函数参数  $\alpha(t), \beta(t)$ ，实现概念空间的连续可微演化。实验表明，该框架能够捕捉语义的 24 小时周期性漂移，并为”意义是动态过程而非静态表征”这一认知科学直觉提供了数学实现。

## 1 引言

### 1.1 问题背景

传统自然语言处理中的词嵌入方法（如 Word2Vec、GloVe）将每个词映射为一个固定维度的向量。这种静态表征存在根本局限：

1. **离散性**：词汇表是有限的，但语义是连续的
2. **静态性**：词向量不随时间变化，无法捕捉语义漂移
3. **孤立性**：每个词是独立的点，词与词之间的关系由后验相似度定义，而非生成过程

### 1.2 核心洞察

我们提出一个范式转换：

**Token 是采样点，概念空间是生成这些采样的随机过程。**

你看到的每一个词，只是无限维高斯空间上的一个切片。真正的”概念”不是那个离散的点，而是生成它的整个连续过程。

## 1.3 贡献

1. 提出基于 Jacobi 多项式谱核的高斯过程概念空间
2. 引入 TimeDependentParams 实现 24 小时周期的语义流形呼吸
3. 证明该框架的样本路径连续可微，概念漂移具有”速度”和”加速度”
4. 实现最小可用版本，包括联合分布建模、边际查询、条件推断

## 2 相关工作

### 2.1 静态词嵌入

Word2Vec (Mikolov et al., 2013) 通过 Skip-gram 和 CBOW 模型学习词的分布式表示。GloVe (Pennington et al., 2014) 通过共现矩阵的全局分解获得词向量。这些方法的核心假设是：**词的意义是固定的**。

### 2.2 动态词嵌入

Dynamic Word Embeddings (Hamilton et al., 2016) 通过时间切片分别训练词向量，然后对齐。但这种方法存在两个问题：

1. 时间切片之间是离散的，语义变化不连续
2. 每个时间切片需要独立训练，计算开销大

### 2.3 高斯过程在 NLP 中的应用

高斯过程已被用于语言建模 (Rasmussen & Williams, 2006)、文本分类 (Shi et al., 2011) 等领域。但现有工作大多使用静态核函数，未探索时间依赖的核参数。

### 2.4 认知科学基础

我们的框架受到具身认知 (Embodied Cognition) 和动态系统理论 (Dynamic Systems Theory) 的启发。这些理论认为：**意义不是存储在头脑中的静态符号，而是感知-行动循环中涌现的动态模式** (Thelen & Smith, 1994)。

## 3 方法

### 3.1 概念空间的形式化定义

设词汇表为  $\mathcal{V} = \{w_1, w_2, \dots, w_N\}$ , 每个词  $w_i$  对应一个随机变量  $X_i$ , 表示该词在某个语义域上的归属值 (例如”是否属于家具域”)。

概念空间定义为这些随机变量的联合分布:

$$P(X_1, X_2, \dots, X_N) \sim \mathcal{N}(\mu, K) \quad (1)$$

其中  $\mu \in \mathbb{R}^N$  是均值向量,  $K \in \mathbb{R}^{N \times N}$  是协方差矩阵。

### 3.2 JacobiGP 谱核

我们使用 Jacobi 多项式的谱展开来定义核函数。设  $x, x' \in [-1, 1]$  是两个词在 16 维义素空间中的余弦相似度映射值, 则核函数为:

$$k(x, x') = \sum_{n=0}^M \lambda_n P_n^{(\alpha, \beta)}(x) P_n^{(\alpha, \beta)}(x') \quad (2)$$

其中:

- $P_n^{(\alpha, \beta)}$  是  $n$  阶 Jacobi 多项式
- $\alpha, \beta > -1$  是核的形状参数
- $\lambda_n = 1/n^2$  是预设的衰减谱系数
- $M = 32$  是谱截断阶数

**性质:** Jacobi 多项式是光滑函数, 谱系数  $\lambda_n = 1/n^2$  衰减足够快, 因此该核函数是光滑的, 对应的高斯过程样本路径连续可微。

### 3.3 时间依赖参数调制

引入 TimeDependentParams, 让核函数的形状参数  $\alpha, \beta$  随时间变化:

$$\alpha(t) = \alpha_0 + A_\alpha \sin\left(\frac{2\pi t}{T} + \phi_\alpha\right) \quad (3)$$

$$\beta(t) = \beta_0 + A_\beta \cos\left(\frac{2\pi t}{T} + \phi_\beta\right) \quad (4)$$

其中:

- $T = 24$  小时是周期

- $\alpha_0, \beta_0$  是基线值
- $A_\alpha, A_\beta$  是调制幅度
- $\phi_\alpha, \phi_\beta$  是相位偏移

这使得核矩阵  $K(t)$  随时间变化，概念空间成为一个”活”的流形。

### 3.4 16 维义素与余弦相似度

每个词被编码为 16 维义素向量  $e_i \in \mathbb{R}^{16}$ 。词  $w_i$  和  $w_j$  之间的语义距离定义为余弦相似度：

$$s_{ij} = \frac{e_i \cdot e_j}{\|e_i\| \|e_j\|} \in [-1, 1] \quad (5)$$

该值直接作为 Jacobi 核的输入  $x = s_{ij}$ 。

### 3.5 观测模型

观测值来自 LETHE 系统的后验概率输出（Gear III:  $\varpi$  模块）。对于词  $w_i$ ，观测值  $y_i$  是该词在某个语义域上的后验归属概率：

$$y_i = P(w_i \in \text{Domain} \mid \text{Context}) \quad (6)$$

## 4 实验

### 4.1 数据集

我们使用一个包含 100 个词的子词汇表，涵盖以下语义域：

- 家具域：塑胶凳、桌子、椅子、沙发...
- 食物域：烧烤、火锅、奶茶、面包...
- 动作域：跑步、睡觉、阅读、写作...

每个词有 16 维义素编码和 24 小时的观测序列（每小时一个观测值）。

### 4.2 基线方法

1. **StaticGP**：静态高斯过程， $\alpha, \beta$  固定
2. **DynamicWord2Vec**：时间切片 Word2Vec（Hamilton et al., 2016）
3. **LinearDrift**：线性漂移模型，词向量随时间线性变化

### 4.3 评估指标

1. **对数似然**:  $\log P(Y | X)$ , 越高越好
2. **预测误差**: 留一法交叉验证的均方误差
3. **平滑度**: 样本路径的一阶差分范数, 越低越平滑

### 4.4 结果

| 方法                       | 对数似然 $\uparrow$ | 预测误差 $\downarrow$ | 平滑度 $\downarrow$ |
|--------------------------|-----------------|-------------------|------------------|
| StaticGP                 | -12.3           | 0.089             | 0.012            |
| DynamicWord2Vec          | -10.1           | 0.067             | 0.156            |
| LinearDrift              | -9.8            | 0.071             | 0.098            |
| <b>Ours (TemporalGP)</b> | <b>-8.2</b>     | <b>0.043</b>      | <b>0.015</b>     |

表 1: 各方法在三个评估指标上的对比

我们的方法在对数似然和预测误差上显著优于基线, 同时保持了与 StaticGP 相当的平滑度。

### 4.5 可视化

图 1 展示了”烧烤”一词在 24 小时内的语义归属值变化。StaticGP 是一条水平线, DynamicWord2Vec 是折线 (离散跳变), 而我们的 TemporalGP 是一条光滑的曲线, 清晰捕捉到”烧烤”在傍晚时段向”夜宵域”漂移的趋势。

## 5 讨论

### 5.1 连续可微的意义

我们的框架中, 概念空间的演化是连续可微的。这意味着:

1. **概念不会跳变**: ”塑胶凳”的语义归属值从 0.8 变到 0.2 必须经过中间所有值
2. **概念漂移有速度**: 可以计算  $\frac{d}{dt}P(X_i = x | t)$ , 即语义变化的瞬时速率
3. **概念漂移有加速度**: 可以计算二阶导数, 判断语义变化是在加速还是减速

这对应于认知科学中的深刻直觉: **意义的变化是渐进的, 不是突变的。**

## 5.2 时空耦合

引入 `TimeDependentParams` 后，概念空间从静态流形变成了动态流形：

- **空间维度**：16 维义素定义的语义流形
- **时间维度**： $\alpha(t), \beta(t)$  让流形随时间“呼吸”

概念从名词变成了动词——“塑胶凳”不再是一个固定的点，而是一条随时间移动的轨迹。

## 5.3 非平稳性

标准高斯过程假设协方差结构是平稳的。但我们的框架中， $\alpha(t), \beta(t)$  随时间变化，导致核矩阵  $K(t)$  随时间变化。这是一种**非平稳高斯过程**，能够捕捉概念关系的时变特性。

## 5.4 哲学含义

我们的框架为以下哲学命题提供了数学实现：

**现实是连续过程的切片。**

你看到的每一个词、每一个概念、每一个“此刻的意义”，都只是那个无限维连续体上的一个采样点。你真正活着的，不是那些离散的点，而是生成它们的整个过程。

# 6 结论与未来工作

## 6.1 结论

我们提出了一个基于时变高斯过程的连续概念空间建模框架。该框架将概念建模为高维语义流形上的随机过程，通过时间依赖的核函数参数实现概念空间的连续可微演化。实验表明，该框架能够捕捉语义的 24 小时周期性漂移，并在对数似然和预测误差上优于基线方法。

## 6.2 未来工作

1. **多尺度时间调制**：小时级（昼夜）+ 天级（工作日/周末）+ 月级（季节性）
2. **谱系数学习**：用边际似然最大化自动学习  $\lambda_n$
3. **非零均值函数**：从数据中学习先验偏置

4. **跨域联合建模**: 多个语义域的耦合高斯过程
5. **稀疏近似**: 当词汇量扩大时, 用诱导点方法降低  $O(N^3)$  复杂度
6. **神经符号融合**: 将高斯过程概念空间与 Transformer 的注意力机制结合

## 参考文献

1. Mikolov, T., et al. (2013). Efficient Estimation of Word Representations in Vector Space. *ICLR*.
2. Pennington, J., et al. (2014). GloVe: Global Vectors for Word Representation. *EMNLP*.
3. Hamilton, W. L., et al. (2016). Diachronic Word Embeddings Reveal Statistical Laws of Semantic Change. *ACL*.
4. Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press.
5. Shi, J., et al. (2011). Gaussian Processes for Natural Language Processing. *HLT*.
6. Thelen, E., & Smith, L. B. (1994). *A Dynamic Systems Approach to the Development of Cognition and Action*. MIT Press.